

基于 BiLSTM-Attention 的 IMDB 影评情感分类

RNN 序列分类实验与消融分析

第二组

深圳北理莫斯科大学

May 25, 2026



深圳北理莫斯科大学

УНИВЕРСИТЕТ МГУ-ППИ В ШЭНЬЧЖЭНЕ
SHENZHEN MSU-BIT UNIVERSITY

- 本实验面向 IMDB 影评二分类任务，目标是根据评论文本判断情感倾向：

$$y \in \{0, 1\}, \quad 0 = \text{negative}, \quad 1 = \text{positive}$$

- 文本评论具有天然的序列结构，词语顺序、上下文关系和转折表达都会影响最终情感判断。
- RNN/LSTM 能够沿时间步建模序列信息，适合处理文本、语音、时间序列等有序数据。

数据与实验设置

项目	设置
数据集	IMDB 影评情感分类数据
数据文件	data/x_train.npy, data/y_train.npy, data/x_val.npy, data/y_val.npy
训练集	31818 条样本, 标签分布 [15875, 15943]
验证集	13636 条样本, 标签分布 [6859, 6777]
序列长度	200, 所有输入均已 padding/truncation 到固定长度
Token 范围	0 ~ 9999, 其中 0 为 padding token
有效词表大小	10000, 即 $\max(\text{token id}) + 1$
Padding 比例	训练集约 19.62%, 验证集约 19.52%
Batch size	256
Embedding size	256
LSTM hidden size	256
Dropout	0.5

数据文件统计

Split	Shape	Label Count	Avg. Valid Len	Rows with Padding
Train	(31818, 200)	[15875, 15943]	160.75	18168
Validation	(13636, 200)	[6859, 6777]	160.97	7755

- 数据中实际出现的最大 token id 为 9999，因此从数据角度有效词表大小为 10000。
- 若模型中 MAX_WORDS 设置大于 10000，多出的 embedding 行不会被当前数据访问，只会增加未使用参数。

总体模型结构

本实验最终模型采用 **Embedding + BiLSTM + Attention + LayerNorm + FC Head** 的结构。

Input $\rightarrow$ Embedding $\rightarrow$ BiLSTM $\rightarrow$ Attention Pooling $\rightarrow$ LayerNorm $\rightarrow$ FC Head $\rightarrow$ LogSoftmax

- 输入形状: $[B, 200]$
- 词向量表示: $[B, 200, 256]$
- BiLSTM 输出: $[B, 200, 512]$
- Attention 聚合后: $[B, 512]$
- 最终输出: $[B, 2]$

- LSTM 通过输入门、遗忘门和输出门控制信息流，缓解普通 RNN 的梯度消失问题。
- 本实验使用双向 LSTM，同时捕捉前文和后文信息：

$$\vec{h}_t = \text{LSTM}_f(x_t, \vec{h}_{t-1})$$

$$\overleftarrow{h}_t = \text{LSTM}_b(x_t, \overleftarrow{h}_{t+1})$$

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] \in \mathbb{R}^{512}$$

- 双向结构适合影评文本中的转折表达，例如 “not bad”、“boring at first but excellent later”。

Attention Pooling

本实验中的 Attention 不是 Transformer 多头自注意力，而是对 BiLSTM 每个时间步输出进行可学习加权汇总。

$$s_t = W_a h_t + b_a \quad (1)$$

$$\alpha_t = \frac{\exp(s_t)}{\sum_{i=1}^T \exp(s_i)} \quad (2)$$

$$c = \sum_{t=1}^T \alpha_t h_t \quad (3)$$

- s_t 表示第 t 个时间步的重要性分数。
- α_t 表示归一化后的注意力权重。
- c 是整条评论的句向量表示，用于后续分类。

核心代码片段

```
class Attention(nn.Module):
    def __init__(self, hidden_size):
        super(Attention, self).__init__()
        self.attention = nn.Linear(hidden_size, 1)

    def forward(self, lstm_output):
        attention_scores = self.attention(lstm_output).squeeze(-1)
        attention_weights = F.softmax(attention_scores, dim=1)
        context_vector = torch.bmm(
            attention_weights.unsqueeze(1), lstm_output
        ).squeeze(1)
        return context_vector, attention_weights
```


当前主模型使用三层全连接预测头，将 Attention 得到的 512 维句向量逐步映射到二分类输出。

$$z_1 = \text{ReLU}(W_1 c + b_1), \quad W_1 \in \mathbb{R}^{256 \times 512} \quad (4)$$

$$z_2 = W_2 z_1 + b_2, \quad W_2 \in \mathbb{R}^{128 \times 256} \quad (5)$$

$$\hat{y} = \text{LogSoftmax}(W_3 z_2 + b_3), \quad W_3 \in \mathbb{R}^{2 \times 128} \quad (6)$$

- LayerNorm 用于稳定 Attention 后的句向量分布。
- Dropout 用于缓解过拟合，提升验证集泛化能力。

- 损失函数采用负对数似然损失：

$$\mathcal{L} = \text{NLLLoss}(\log p, y)$$

- 优化器采用 Adam，学习率设为 10^{-3} 。
- 每轮训练后在验证集上评估 Accuracy。
- 当验证集准确率提升时保存模型参数：

$$\text{best_acc} = \max(\text{best_acc}, \text{acc}_{\text{val}})$$

- 使用 early stopping，连续 6 轮无提升则停止训练。

主模型结果

Model	Best Epoch	Val Accuracy	Correct / Total
BiLSTM + Attention + LayerNorm + 3-layer FC	15	88.92%	12125 / 13636

- 该结果来自当前 notebook 输出记录。
- 模型在第 15 轮达到最佳验证准确率，之后验证集表现开始波动，early stopping 可以保留最佳参数。

实验结果总体观察

- 所有实验均在相同数据划分、batch size、优化器、学习率、随机种子和 early stopping 设置下运行。
- 主模型 **BiLSTM + Attention + 3-layer FC** 达到最高验证准确率：

$$\text{Acc}_{\text{val}} = 88.92\%, \quad 12125/13636$$

- Pooling 对比中，Attention 相比 Last Hidden 提升约 1.06 个百分点：

$$88.92\% - 87.86\% = 1.06\%$$

- FC Head 消融中，各预测头差距较小，说明主要性能来源是 **BiLSTM** 编码层和序列聚合方式。

对比模型：不同序列聚合方式

Model	Aggregation	Val Acc.	Params	Observation
BiLSTM + Last Hidden	last state	87.86%	low	只使用最后状态，容易遗漏中间关键词。
BiLSTM + Mean Pooling	mean	88.30%	low	对所有时间步平均，稳定但区分度较弱。
BiLSTM + Max Pooling	max	88.49%	low	强调局部强特征，适合情感关键词。
BiLSTM + Mixed Pooling	mean + max	88.30%	medium	同时保留整体语义和局部强响应。
BiLSTM + Attention	learnable weighted sum	88.92%	medium	自动学习不同时间步的重要性，解释性更好。

注：所有模型均使用相同数据划分、随机种子、优化器、batch size 与 early stopping 策略。

对比模型分析

- **Last Hidden** 最低：best acc 为 87.86%。IMDB 输入采用 post-padding，最后时间步容易受到 padding 区域影响；同时，评论情感不一定集中在序列末尾。
- **Mean Pooling** 与 **Mixed Pooling** 持平：二者均为 88.30%。Mean 能保留整体语义，但会平均掉强情感词；Mixed 拼接 mean 和 max 后维度增大，但没有带来稳定收益。
- **Max Pooling** 略高于 **Mean**：best acc 为 88.49%。这说明情感分类中局部强特征有价值，例如“excellent”，“terrible”，“boring”等词。
- **Attention** 最优：best acc 为 88.92%。Attention 不使用固定规则聚合，而是学习每个时间步的重要性，因此能同时利用整体上下文和关键情感片段。
- 从结果看，序列聚合方式对模型性能影响明显，优先级高于单纯调整预测头层数。

Pooling 结果排序

Rank	Aggregation	Best Acc.	Gap to Attention
1	Attention	88.92%	0.00%
2	Max Pooling	88.49%	-0.43%
3	Mean Pooling	88.30%	-0.62%
4	Mixed Pooling	88.30%	-0.62%
5	Last Hidden	87.86%	-1.06%

- 固定 pooling 方法虽然简单，但无法根据样本内容动态调整关注位置。
- Attention 的提升幅度不大但稳定，适合作为本实验最终聚合模块。

消融实验：不同 FC 预测头

Variant	FC Head	Val Acc.	Complexity	Design Motivation
Head-A	Linear(512, 2)	88.77%	low	直接分类，参数最少。
Head-B	512 $\rightarrow$ 256 $\rightarrow$ 2	88.79%	medium	增加一层非线性变换。
Head-C	512 $\rightarrow$ 256 $\rightarrow$ 128 $\rightarrow$ 2	88.92%	medium	当前 notebook 主模型。
Head-D	512 $\rightarrow$ 256 $\rightarrow$ ReLU $\rightarrow$ 128 $\rightarrow$ ReLU $\rightarrow$ 2	88.91%	medium	在 fc2 后补充激活，增强非线性表达。
Head-E	512 $\rightarrow$ 512 $\rightarrow$ 256 $\rightarrow$ 2	88.50%	high	更宽预测头，检验参数量收益。

消融实验建议保持 Embedding、BiLSTM、Attention、优化器和训练轮数一致，仅替换预测头结构。

- 单层线性头已经达到 **88.77%**：说明 Attention 后得到的句向量已经具有较强线性可分性。
- 两层头为 **88.79%**，三层头为 **88.92%**：增加适量非线性有小幅提升，但提升空间有限。
- **fc2** 后加入 **ReLU** 达到 **88.91%**：与原三层头几乎持平，说明该修改合理，但在当前设置下没有形成明显优势。
- 更宽预测头下降到 **88.50%**：参数量增加并不必然提升泛化效果，过宽的分类头可能更容易拟合训练集细节。
- 因此，本实验最终选择 $512 \rightarrow 256 \rightarrow 128 \rightarrow 2$ 的三层预测头，兼顾准确率和模型复杂度。

FC Head 结果排序

Rank	FC Head	Best Acc.	Best Epoch
1	512 $\rightarrow$ 256 $\rightarrow$ 128 $\rightarrow$ 2	88.92%	15
2	fc2 后加入 ReLU	88.91%	18
3	512 $\rightarrow$ 256 $\rightarrow$ 2	88.79%	10
4	Linear(512, 2)	88.77%	17
5	512 $\rightarrow$ 512 $\rightarrow$ 256 $\rightarrow$ 2	88.50%	6

- 不同 FC head 的最大差距约 0.42 个百分点，小于 pooling 对比中的最大差距。
- 预测头越复杂不一定越好，分类头应与编码表示质量和正则强度匹配。

- 数据中 padding token 为 0，约有 57% 的样本存在 post-padding。
- 仅在 Attention 上做 padding mask 时，准确率不一定提升。
- 原因是 BiLSTM 已经先处理了 padding，尤其反向 LSTM 会从 padding 区域开始读取。
- 因此更完整的做法应是：

`padding_idx + pack_padded_sequence + masked attention`

- 本实验最终保留了未 mask 的 Attention 版本，以验证集准确率作为模型选择依据。

RNN 与其他序列分类网络

除 RNN/LSTM/GRU 外，Transformer Encoder 也适合序列分类任务。

Aspect	RNN/LSTM	Transformer Encoder
建模方式	递归地按时间步读取序列	通过 self-attention 建立全局依赖
顺序信息	天然包含时间顺序	需要位置编码
并行能力	较弱，时间步依赖明显	较强，可并行处理序列
长距离依赖	LSTM 有改善但仍受限制	任意位置可直接交互
适用场景	小中规模数据、资源有限实验	大规模数据、预训练模型、长文本任务

- BiLSTM 能够同时利用评论文本的前向与后向上下文信息。
- Attention Pooling 在五种聚合方式中效果最好，验证集准确率达到 **88.92%**。
- Max Pooling 优于 Mean Pooling，说明情感分类任务对局部强情感特征较敏感。
- FC 消融显示预测头结构影响较小，三层 FC 与 fc2 后加 ReLU 的结果几乎持平。
- 当前主模型在验证集上取得 **88.92%** 的最佳准确率，说明 BiLSTM-Attention 是 IMDB 文本情感分类的有效方案。
- 实验表明：对本任务而言，优化序列表示和聚合方式比单纯加宽预测头更重要。

Thanks!